

Cosmos Policy 端侧低精度推理阶段报告

Cosmos Policy 端侧低精度推理阶段报告

日期：2026-07-29

分支：exp/cosmos-tensorrt-fp8

硬件：NVIDIA GeForce RTX 4090 D, Ada sm_89, 24 GB

实验目录：experiments/cosmos_trt_quantization/

1. 摘要

本阶段实际完成了环境隔离、固定输入捕获、单步 DiT wrapper、六种 torchao 模式的 30+200 latency 测量、四种模式的 torch.profiler trace、BF16 Nsight Systems trace、BF16 TensorRT full-graph 编译尝试、100+1000 单 denoiser BF16 eager 基准和 1-5 步 100+300 sweep。

核心结论：

1. torchao W8A8 的主要瓶颈是 1400 次动态 activation scale 及其引发的 50424 次 `_local_scalar_dense`、约 6.7 万次 D2H 小传输；INT4-WO 则有 1400 次 `tinygemm`，累计 1246.17 ms。
2. Cosmos DiT 在替换 `export-hostile` 的 `TransformerEngine` 算子并增加一个 BF16 cast converter 后，能够在内存中编译为单一 TensorRT 分区：6492/6492 算子支持、无 PyTorch fallback。
3. 该 BF16 engine 的序列化失败：PyTorch 2.7 的 `ExportedProgram` 路径对大于 4 GiB 的 engine string 使用了不足的 pickle protocol。随后已实现 TorchScript 保存路径，但继续执行环境不再暴露 `/dev/nvidia*`，无法重建、重载和计时。因此 BF16 TensorRT 尚不是稳定 baseline。
4. 由于 BF16 TensorRT 稳定性门禁未通过，严格没有开始 ModelOpt FP8 PTQ、FP8 engine、原始 LIBERO rollout 或 LIBERO-Plus rollout；不能声称获得 TensorRT FP8 加速。

5. BF16 eager 的 3-step policy p50 为 326.39 ms，相对 5-step 的 448.42 ms 快 1.37×；固定输入 action cosine 为 0.9999992、L2 为 0.00613，是当前最有希望的 latency-error 候选，但尚无 rollout 成功率 证据。

2. 上一阶段结果回顾

上一阶段在原始 LIBERO-10 上得到 BF16 48/50，policy latency 约 492 ms；torchao INT8-WO、W8A8、INT4-WO 分别约 608、2530、1506 ms。torch.compile 未改善这些量化路径。上述结果构成本阶段“停止扩大 torchao rollout、转向 静态 NVIDIA engine”的依据。

3. 为什么没有使用 llama.cpp

Cosmos Policy 是带视频 latent、时序条件、cross-attention 和扩散 scheduler 的 DiT policy，不是标准自回归 LLM。其主干输入为 [B,C,T,H,W] 视频/动作 latent，推理要重复调用 denoiser；llama.cpp 的 token-by-token KV-cache/GGUF 路径与该计算图不匹配，因此本阶段没有使用。

4. 环境审计

主环境保持不变，新增隔离环境 /data/rxhuang/envs/cosmos-trt：

组件	版本/状态
GPU	RTX 4090 D，compute capability 8.9
Driver	560.35.03
PyTorch / CUDA runtime	2.7.0+cu128 / 12.8
系统 CUDA toolkit	12.6.85
cuDNN	9.7.1
torchao	0.11.0
TransformerEngine	2.2
TensorRT	10.9.0.34（隔离环境）
Torch-TensorRT	2.7.0（隔离环境）
NVIDIA ModelOpt	0.27.0（隔离环境）
ONNX / ORT GPU	1.17.0 / 1.20.1
TensorRT-RTX	未安装
trtexec	系统无可执行文件
	2024.5.1 / 2024.3.2

组件	版本/状态
Nsight Systems / Compute	

Ada sm_89 可测试 FP8，但本报告没有测试或声称 NVFP4。完整安装命令见 configs/environment.lock.md；主 .venv 中的 PyTorch/CUDA 未被替换。

5. torchao 量化变慢的具体原因

统一 policy 基准（30 warm-up + 200 measured）：

模式	p50	p95	p99	相对 BF16
BF16 eager	461.02	540.40	568.13	1.000×
fake INT4	451.19	511.77	555.60	1.022×
INT8-WO	552.32	633.69	660.80	0.835×
torchao FP8	1021.65	1093.72	1130.93	0.451×
INT4-WO	1494.88	1566.30	1589.56	0.308×
W8A8	2512.16	2581.07	2662.31	0.184×

单位均为 ms。

W8A8

- 1400 次 `ampere_igemm_int8_128x128_ldg4_nn` 只花约 219.20 ms；
- 动态 quantize kernel 9866 次、约 161.06 ms；
- `cast/copy` 83679 次、约 175.46 ms；
- 50423 次 `D2H pinned`、16801 次 `D2H pageable`；
- `_local_scalar_dense` 50424 次；
- 总 GPU 事件 115765 次，是 BF16 9370 次的 12.35 倍。

所以 W8A8 主要慢在动态 activation scale、device scalar 同步和 launch 开销，而非 INT8 GEMM 本身。

INT8 weight-only

主 GEMM 仍是 `ampere_bf16_s1688gemm_bf16_*`。该路径把量化权重恢复/转换后做 BF16 GEMM，额外增加 1401 次 `direct-copy/cast` 和大量 `elementwise`。它是显存格式优化，不是该 shape 下的真实 INT8 计算加速。

INT4 weight-only

1400 次

tinygemm_m16n8k16_chunk_kernel<..., BLayout_TC_int4<8, 128>, ...> 累计 1246.17 ms, 占 trace GPU 时间 86.68%。INT4 unpack 与计算融合在该 kernel 内, 无法诚实地拆出独立 unpack 时间; 可以明确的是 batch=1、M=1764、K/N=2048/8192 的 DiT shape 没有从 tinygemm 获益。

BF16 融合路径和 torch.compile

BF16 已走 Tensor Core GEMM、FlashAttention、transformer_engine::normalization::rmsnorm_fwd_general_kernel 和 transformer_engine::fused_rope_forward_kernel。替换 Linear 后产生的 scale/cast 边界破坏了连续 BF16 路径。

Dynamo 不能 trace

transformer_engine_torch.PyCapsule.rmsnorm_fwd, 并对 checkpoint context_fn 给出警告。上一阶段 compiled p50 与 eager 基本相同, 因为 compile 不能消除 torchao kernel 内部的 dynamic scale、D2H 同步或 tinygemm shape 问题。完整证据见 report/torchao_latency_diagnosis.md。

6. Cosmos DiT wrapper

wrappers/cosmos_denoiser_wrapper.py 直接包裹真实 MinimalV1LVGDiT.forward, 不包含 LIBERO env、tokenizer、VAE、文件 I/O 或 Python scheduler。真实捕获输入:

张量	shape	dtype
noisy/action latent	[1, 16, 9, 28, 28]	BF16
timestep	[1, 9]	BF16
text/cross-attention	[1, 512, 1024]	BF16
condition mask	[1, 1, 9, 28, 28]	FP32
fps	[1]	BF16
padding mask	[1, 1, 224, 224]	BF16

wrapper 与原始 net 输出 shape/dtype 完全一致, cosine 1.000000119、max abs 0、重复执行 max abs 0, 无 NaN/Inf。fixture 只有 1.4 MB, 位于 calibration/fixed_denoiser_inputs.pt。

7. TensorRT 编译方法

按顺序实际尝试：

1. 原生 TE graph：FakeTensor export 在 TE RMSNorm 报 Input x is not allocated。
2. 替换 113 个 TE RMSNorm：可继续导出，但仍遇到 TE attention/RoPE。
3. 再替换 56 个 TE attention 为 PyTorch SDPA，并关闭 fused RoPE：torch.export 成功。
4. Torch-TensorRT 内置 capability validator 把 454 个 aten._to_copy(dtype=BF16) 错判为不支持；原始 dry-run 为 6038/6492 (93.01%)，61 个 TRT 分区 + 61 个 PyTorch 分区。
5. 在仓库内注册仅匹配 BF16 的高优先级 cast converter 后，dry-run 为 6492/6492、单一 TRT 分区。
6. 实际 build 又遇到 padding mask repeat 被分解成临时 10-D expand，超过 TensorRT shuffle rank。将其改为语义等价的 5-D expand 后，full graph engine 在内存中成功构建。

8. BF16 TensorRT baseline

成功部分

- build 时间：388.05 s；
- 节点覆盖率：100% (6492/6492)；
- 参数覆盖率：100%；
- TRT 分区：1；
- PyTorch fallback：0；
- engine boundary：0；
- 输出 finite；
- 相对重写后 eager：cosine 0.9999347，max abs 0.109375，L2 4.12242。

未通过部分

engine 未能持久化。torch_tensorrt.save(..., exported_program) 失败：

```
OverflowError: serializing a string larger than 4 GiB requires pickle protocol 4 or higher
```

已将保存实现改为 TorchScript zip 路径，但后续执行容器不再暴露 /dev/nvidia*，无法重新 build、reload 和 benchmark。因而：

- 不能给出 BF16 TRT p50/p95；
- 不能证明 engine 可重复加载；

- 不能把“内存中构建成功”写成“稳定 BF16 TensorRT baseline”；
- engines/ 中只有 3.7 GB 的 exported program 中间产物，不是可用 engine。

另一个数值限制是 TE→ATen 重写本身相对原始 eager cosine 0.9999757，未达到 wrapper 的严格 0.99999 等价门槛，但高于本阶段 engine action gate 0.999。engine 对原始未重写 graph 的组合误差没有直接实测，因此不外推。

9. FP8 PTQ 方法与 Calibration 数据

本阶段在 BF16 TensorRT 稳定性门禁处停止。没有采集 128-512 条 calibration observation，没有生成 ModelOpt scale，也没有构建 FP8 engine。这样做是为了避免在 BF16 engine 尚不能持久化/复载时产生不可比较的 FP8 结果。

计划保持不变：未来使用原始无扰动 LIBERO、多 suite/task/seed 的 agent view、wrist、proprio 和文本 embedding，ModelOpt 静态 PTQ + 显式 Q/DQ；norm、softmax、timestep、scheduler 和 action reconstruction 默认 BF16。

10. 实际层精度

由于 FP8 PTQ 未开始，没有可报告的逐层实际 TensorRT precision、Q/DQ scale 或 layer output error。不能把 torchao FP8 的 280 个动态量化 Linear 当作 TensorRT FP8 层精度审计。

11. TensorRT 覆盖率

图版本	节点覆盖	参数覆盖	TRT/ PyTorch 分区	fallback
原生 TE	export 失败	不适用	不适用	不适用
TE 重写、内置 converter	93.01%	近似 100%	61 / 61	454 个 cast
+ BF16 cast converter + mask rewrite	100%	100%	1 / 0	0

FLOP/latency 覆盖没有用虚构数字填充。最终图按节点和参数为 100%，但没有持久化 engine 的 latency trace，故 latency coverage 标为不可用。

12. Microbenchmark

单 denoiser BF16 eager 使用 100 warm-up + 1000 measured :

- mean 61.00 ms ;
- p50 60.58 ms ;
- p95 63.94 ms ;
- p99 68.11 ms。

BF16 TRT/FP8 TRT 因 engine 不可复载而没有计时。真正量化 speedup 必须比较 BF16 TRT 与 FP8 TRT ; 本报告没有用 BF16 eager 对 torchao FP8 的结果冒充 TensorRT precision speedup。

13. 完整 policy latency

完整 5-step policy 的 30+200 基准见第 5 节。BF16 p50 461.02 ms ; torchao FP8、INT8-WO、W8A8、INT4-WO 均更慢。没有 BF16 TRT/FP8 TRT p50/p95。

14. 显存

本轮单进程 profiler 的 max_memory_allocated 六种模式均约 7727 MB ; 该数字 包含完整 policy、tokenizer/缓存和 allocator 行为，不足以证明 torchao 显存 没有下降。由于没有持久化 TRT engine，也没有可比较的 engine peak memory 与 engine size。图表对缺失值留空，而不是填 0。

15. 数值误差

相对固定 BF16 action :

模式	cosine	L1	L2	max abs	NaN/Inf
INT8-WO	0.9999960	0.000890	0.01422	0.00463	0
W8A8	0.9999808	0.002116	0.03078	0.00762	0
torchao FP8	0.9999405	0.004829	0.07526	0.02830	0
INT4-WO	0.9996271	0.007914	0.14068	0.05843	0
fake INT4	0.9995420	0.009591	0.15210	0.05004	0

torchao FP8 不是 TensorRT FP8，不能回答 TensorRT FP8 是否降低 action 精度。

16. 去噪步数实验

每个配置 100 warm-up + 300 measured, 同一 observation、seed 和 scheduler :

配置	policy p50 / p95 (ms)	实际 denoiser total p50	cosine vs 5-step	L2
1-step	200.69 / 243.37	60.22	0.9999612	0.04385
2-step	201.57 / 266.61	60.19	0.9999612	0.04385
3-step	326.39 / 388.22	180.32	0.9999992	0.00613
4-step	387.79 / 446.32	240.15	0.9999994	0.00549
5-step	448.42 / 513.93	300.00	1.0000000	0

当前 scheduler 下 1-step 和 2-step 都只发生一次 net forward, 因此输出完全 相同; 这不是测量错误, 也不能把“2”解释为两次 denoiser。3-step 相对 5-step p50 快 1.37 $\times$, 且固定输入误差很小, 是最合理的下一轮 rollout 候选。

不过单 observation 的 action cosine 不能替代成功率。当前最佳“已验证成功率”配置仍是上一阶段 BF16 eager 5-step; 当前最佳 microbenchmark Pareto 候选是 BF16 eager 3-step。

17. 原始 LIBERO pilot

未运行。原因不是算力不足, 而是 speedup gate 明确要求稳定、可复载、已计时的 BF16/FP8 TensorRT engine。本阶段没有满足。

18. LIBERO-Plus pilot

未运行, 也没有扩大已知很慢的 torchao W8A8/INT4 rollout。符合阶段门禁。

19. 失败配置

配置/阶段	失败原因	证据
原生 TE export		attempt0 log/report

配置/阶段	失败原因	证据
	TE RMSNorm FakeTensor 无 storage	
TE attention/RoPE export	fused RoPE/export 不兼容	attempt2 log/report
内置 converter full compile	BF16 _to_copy validator 漏项	dry-run report
首次 custom converter build	10-D expand 超 TRT shuffle rank	build log
最终 full graph save	>4 GiB string / pickle protocol	partition report
TorchScript follow- up	后续容器无 /dev/ nvidia*	final status
W8A8 Nsight follow-up	权限切换后报告未落盘	nsys log

20. 局限性

- 固定 observation microbenchmark 不能代表任务成功率分布；
- 没有 BF16 TRT 可复载 engine，因此没有 BF16 TRT latency；
- 没有 FP8 calibration、layer precision 或 TensorRT FP8 latency；
- BF16 TensorRT 使用了 TE→ATen 语义近似重写；
- profiler 会放大 CPU 调度时间，kernel 总时间和事件计数比 profile wall time 更适合做归因；
- GPU clock 未锁定，但各正式模式固定单卡、独立进程并记录 p50/p95/p99；
- 当前共享 LIBERO-Plus task order 在实验期间漂移为 2519 项，固定输入文本用 最长原始指令前缀匹配缓存，已记录在 RUNBOOK。

21. 是否值得继续量化研究

torchao 动态量化路径不值得继续扩大 rollout。TensorRT 路线仍有研究价值，因为 full graph 已证明可以达到单分区、零 fallback；下一个工程问题是大 engine 持久化，而不是算子覆盖。只有解决保存/重载后，ModelOpt 静态 FP8 才值得继续。

22. 是否达到端侧加速目标

没有。当前没有 BF16 TRT vs FP8 TRT 的公平 latency 对照，也没有满足 $FP8 \geq 1.20 \times \text{speedup gate}$ 。不能声称获得低比特端侧加速。

去噪步数方面，3-step 在 microbenchmark 上已达到 $1.37\times$ ，比现有 torchao 量化更有效；但没有 rollout 成功率，暂时只能称为候选。

23. 下一阶段异步框架计划

现有 open-loop 流程是“完整推理 chunk $\rightarrow$ 执行 E 个 action $\rightarrow$ 停止 $\rightarrow$ 再推理”，不是真正 inference/execution overlap。详细方案位于 report/async_pipeline_design.md，包含：

- inference worker 与 action execution worker；
- observation/inference 时间戳；
- global action index、chunk start、execution cursor；
- deadline、stale chunk、replacement；
- prefix freezing、action inpainting/overlap；
- deadline miss rate、observation age 和 overlap ratio。

在 engine 尚不可复载前不大改运行框架。3-step 可先在同步原始 LIBERO pilot 中验证；真正异步实验仍应等待稳定 backend。

24. 完整复现命令

```
cd /home/rxhuang/Projects/cosmos-policy
git switch exp/cosmos-tensorrt-fp8

# wrapper
CUDA_VISIBLE_DEVICES=5 .venv/bin/pytest -q \
    experiments/cosmos_trt_quantization/tests/
    test_cosmos_denoiser_wrapper.py

# torchao latency (每个 mode 独立进程)
source experiments/liberoplus_quantization/env.sh
CUDA_VISIBLE_DEVICES=7 MUJOCO_EGL_DEVICE_ID=7 .venv/bin/python \
    experiments/cosmos_trt_quantization/scripts/profile_torchao.py \
    --mode int8_backbone --phase latency --warmup 30 --iters 200

# torch.profiler
CUDA_VISIBLE_DEVICES=7 MUJOCO_EGL_DEVICE_ID=7 .venv/bin/python \
    experiments/cosmos_trt_quantization/scripts/profile_torchao.py \
    --mode int4_weight_only --phase torchprof --warmup 30

# TensorRT (隔离环境)
source /data/rxhuang/envs/cosmos-trt/bin/activate
CUDA_VISIBLE_DEVICES=5 python \
    experiments/cosmos_trt_quantization/scripts/build_bf16_trt.py \
```

```

--rewrite-te all --require-full --register-bf16-cast-converter \
--workspace-gb 8

# 单denoiser eager
CUDA_VISIBLE_DEVICES=5 python \
    experiments/cosmos_trt_quantization/scripts/
        benchmark_denoiser.py \
        --backend bf16_eager --warmup 100 --iters 1000

# 1-5 steps
source experiments/liberoplus_quantization/env.sh
CUDA_VISIBLE_DEVICES=6 MUJOCO_EGL_DEVICE_ID=6 .venv/bin/python \
    experiments/cosmos_trt_quantization/scripts/denoising_sweep.py \
    --warmup 100 --iters 300

# 汇总和图
python experiments/cosmos_trt_quantization/scripts/
    summarize_results.py
python experiments/cosmos_trt_quantization/scripts/make_figures.py

```

25. 结果索引

- 汇总：summaries/backend_latency_summary.csv
- speedup gate：summaries/speedup_gate.json
- BF16 TRT 最终状态：summaries/bf16_trt_final_status.json
- 去噪 sweep：summaries/denoising_sweep_summary.csv
- kernel 汇总：profiles/torchao_kernel_summary.csv
- graph break：profiles/torchao_graph_breaks.txt
- TRT coverage：profiles/bf16_trt_dryrun*.txt
- 构建日志：logs/bf16_trt_build*.log
- 图表：figures/（14 组 PNG 300 DPI + PDF）
- 异步设计：report/async_pipeline_design.md