

Cosmos WAM 深度设计探索：实验全景、机制解释与结论

面向系统/机器人研究讨论的中文总结报告

基于仓库中已完成的报告、JSON 汇总和已保存图表生成；不含新的模型推理、仿真或数据采样。生成版本：
b622132b915774ae3eabea584f3fe44578962a39。

一句话结论。 这轮探索最可信的正面机制不是“更聪明地决定何时看新图像”，而是：**把新鲜物理视觉在单次去噪之前写进持续的联合条件 latent**。PV0 因此能在离线状态和新任务上系统地把预测复用 P1 拉回接近 F1 的动作。相反，基于中间层特征的风险分数、廉价图像差分、预测年龄和自适应 scheduler 都没有形成可部署证据。

1. 问题：为什么要研究“复用”而不是每步全新感知？

Cosmos WAM 每次根据视觉、机器人状态和语言生成未来 16 步动作（H=16）。F1 表示每次都重新编码当前观测；P1 表示把上一次预测的未来视觉当作下一次的当前视觉，从而省去昂贵的视觉编码。直观地说，P1 像机器人“相信自己刚才对未来的想象”。它会更快，但一旦执行后的真实世界偏离想象，误差会累积。


本轮的共同约束是：只用原始、未 finetune 的 Cosmos LIBERO checkpoint；denoise=1；不使用 Cosmos value；不训练；不把 simulator 的特权状态输入模型。所有 simulator state 只用于把过去的物理时刻复原成普通 RGB/本体观测。因此，结论讨论的是运行时系统接口，而非通过训练获得的额外能力。

2. 实验路线图：从“哪里修”到“能否选择性修”

阶段	核心问题	规模/对象	结论
机制发现	新鲜信息在网络的哪一层仍可影响动作？	240 executed states; 60 repair states	早层视觉修复强，晚层不可逆；PV0 的“早到”接口值得做。
PV0 / Foundation V2	持续条件修复能否等价接近 F1？	3,801 states / 40 tasks; 600 closed-loop episodes	状态级 fidelity 强；闭环 PV0 明显好于 P1，但不是全面替代 F1。
固定复用与执行反馈	能否安全地多复用几次？	8 tasks pilot / 40 episodes	R2 是效率候选；不支持自适应 feedback scheduler。
ESP	能否靠差分 probing 或选择相机来决定是否 refresh？	12 tasks / 48-state pilot	相关弱且成本不合格，NO-GO。
E4-E6	中间层 feature + 物理创新能否预测 P1 风险？	512 states / 16 tasks	历史离线相关性存在，但 runtime 和 route 合法性都不支持部署。
E8-E11	能否用“预测年龄”或 F1 score 做 commitment？	严格 temporal audit; 32 discovery states	E8 标签本身无效；E11 F1 transfer 失败。
E12		128 states / 8 new tasks	


3. 机制发现：为什么“中间层晚修”通常不工作？

最早的诊断不是直接做 scheduler，而是问一个更基础的问题：如果 F1 和 P1 看到了不同视觉，哪个网络位置还保留了把动作拉回 F1 的机会？研究者在不同 block 把真实视觉或动作 slot 替换进去，观察动作恢复程度。



已保存的 activation-repair frontier：越靠前插入真实视觉，越能恢复 F1 动作；到 block 24，视觉修复几乎失效，动作 slot 修复反而变强。

结果很一致：在 block 4，视觉修复的动作恢复中位数约 92.1%；到 block 24 仅约 0.9%。相反，直接修 action slot 的恢复从早层几乎为零升到 block 24 的 61.8%。用通俗的话说，网络先把“看见了什么”逐步翻译成“该怎么动”；翻译到很后面，再把画面塞回去已经来不及，控制含义已经被编译进动作表示。



已保存的因果传播图：不同观测替换会沿网络深度放大，并最终改变动作。


低秩 PCA/SVD 修复也没有救回来：rank-32 虽能保留不少能量，却只恢复了 exact visual patch 约 28.3% 的动作收益。这说明“最显著的变化方向”不等于“最控制相关的变化方向”。因此 hidden patch、x0 patch、稀疏 patch 和通用低秩校正没有被发展成方法。

由此得到 PV0 的设计原则：不在后层打补丁，而让真实视觉作为一个因果条件，在模型尚未把视觉编译为动作之前进入联合 latent。PV0 是系统接口修复，不是对网络内部激活的事后修改。

4. PV0：真正 work 的机制是什么？

PV0 (native persistent-condition correction) 的做法是：保留上一轮生成的联合 latent 作为预测上下文，但在单次 denoiser forward 之前插入新鲜视觉前缀 (13 帧)。这保留了复用的长期上下文，同时让当前物理证据有机会改变接下来的动作。它与 F1 的区别是不会完全丢掉持续 latent；与 P1 的区别是不会把预测画面当作未经验证的现实。

PV0 全规模闭环：接近 F1，明显优于 P1



另有 128 个新任务状态：PV0 比 P1 更接近 F1 的比例为 100%，中位恢复率 97.8%。


根据 FINAL_PV0_REPORT_ZH.md 与 E12 已保存汇总数字重新绘制。闭环成功率和状态级恢复是不同指标，应同时阅读。

Foundation V2 的状态级实验覆盖 3,801 个状态、40 个任务，PV0 在多个执行前缀下都非常接近 F1；在 heldout 的状态汇总中，PV0 对 F1 的 mean-step L2 约为 0.002，而 P1 对 F1 的偏差量级约 0.7。这里的意义不是“PV0 自己完成任务”，而是它在同一个物理状态下生成的动作几乎和全新观测 F1 一致。

闭环成功是更严格但更噪的指标。600 episode 汇总中 F1 为 19/200，P1 为 11/200，PV0 为 17/200；PV0→P1 的 paired wins/losses 为 6/0。PV0 没有超过 F1，却明显弥补了 P1 的退化。这是正确的科学表述：**PV0 是“预测复用的物理校正”，不是“全面取代新鲜观测”。**

E12 又在 8 个新任务、128 个 H=16 对齐状态上独立复现这个机制：PV0 比 P1 更接近 F1 的比例为 128/128；相对恢复率中位数为 97.8%；P1 风险中位数 0.0924，PV0 风险中位数 0.0019。这是本轮最干净、跨任务的正面证据。

5. 固定复用：为什么 R2 只是候选？



根据 FIXED_REUSE_PILOT_REPORT.json 重绘。8 episodes/route 的成功率样本很小，不能当作跨任务显著性结论。

R1、R2、R3 表示一次 PV0 后连续复用 1、2、3 次 P1。小规模配对 pilot 中，R2 的成功率与 F1/PV0-always 都是 2/8，同时 P1 请求占 61.9%，比 R1 与 R3 看起来更稳。它的价值是说明“两个 P1 之间插一次 PV0”可能取得效率折中；但每条 route 只有 8 episodes，且尚未完成匹配 stale baseline 的充分大样本比较。因此 R2 只能标为 GO-CANDIDATE，不能声称最终 scheduler，更不能由此推出自适应执行反馈策略。


6. 为什么 ESP / 相机选择不 work？

ESP 试图用外部图像的小扰动、raw-frame 差分或选择性相机 refresh 来判断何时需要新视觉。它的好处是概念上直观：画面变化大就刷新，变化小就复用。但实验证明这个直觉不能同时满足“有效”和“便宜”。

E1 发现相机 refresh 不是独立可拆分的计算：F1 中位 246.5 ms、P1 73.95 ms，refresh 的差额占 F1 的约 70%。E2 的 48 状态 pilot 的任务内切换比例为 27.1%，说明确实存在状态变化，但这并不等于可预测控制风险。E3 里不同 early-prefix 长度的 task-balanced Spearman 大多在 -0.12 到 0.19；而双相机 exact-prefix 的额外成本即使 k=2 也约为 F1 的 29.5%，远高于 5% runtime gate。因此 ESP 同时在统计关联与系统成本上失败，停止扩展到 300-state formal study 是合理的预注册止损，而不是遗漏实验。

7. 中间层 feature：早期为什么像是有效，最后为何仍 NO-GO？

E4 的想法很自然：既然 DiT 中间层已经把“视觉是否会影响动作”的信息传向 action slot，能否被动读取一些标量来预测本次复用有多危险？具体做法是在 7 个 block (4/8/12/16/20/24/27) 采 12 个 latent summary，再加入 5 个动作几何量，得到 89 features。没有额外 forward，也没有 attention probing。



根据 E4/E5/E6_RESULT 与 E4/E11 runtime 汇总重新绘制。左图是历史 heldout 离线排序，不等于部署有效性。

在历史 E4 状态上，内部+动作分数的 heldout task-balanced Spearman 是 0.651，超过纯动作 0.563，表明内部表示确实含有额外的离线预测信号。E5 的廉价 raw frame/gradient 差分成本低（中位约 2.92 ms），但 heldout rho 只有 0.453，且一个任务负相关；所以“画面变化大就是风险大”不具备稳定泛化。E6 中 sensitivity 与 innovation 的加法组合 rho 0.747，乘法 0.734。乘法虽然优于两个单项，却输给加法，不能支持原先“语义敏感性 × 物理创新”这一更强的机制说法。

即便先不谈后续的 route 问题，E4 也没有通过系统门槛：P1 baseline 73.61 ms，读取全部 89 summaries 后 78.87 ms，增加 5.25 ms，相当于 clean F1 的 2.13%，超过预注册的 1%。native GPU scorer preflight 没能解决问题：它在 12 states × 20 repeats 下约 85.05 ms，比 baseline 仍高 7.44 ms，且不是正式 100-repeat profile。


更重要的后续源码审计：历史 E4 extractor 把 raw 的上一轮 generated latent 直接送入 forward，没有把预测 future slots 6/7 搬到 current slots 2/3。因此它测到的是 stale-condition reuse 变体，而不是部署中的 predicted-reuse P1。历史相关性是对那个变体的真实描述，但不能直接外推为部署 P1 的证据。

8. E8/E11/E12：严格的时间与 route 合法性如何改变结论？

E8 本来要研究“预测越旧是否越不可靠”。但模型只有固定 H=16 的 future target：把 t+16 的预测画面同 t+K (K≠16) 的真实画面比较，混合了不同物理时间，测到的是标签错配而非 prediction aging。因此 E8 的 formal samples 是 0，E9 优化与 E10 policy 都没有运行。这不是经验上的“没效果”，而是实验定义无效；停止是正确结果。

E11 接着测试能否把冻结 E4 分数搬到 F1 anchor 上，再使用合法的 t+16 retrospective target。32 个新 discovery states 上，F1 score 与 P1 score 排序相关高达 0.955，但 F1 score 与目标的 task-balanced rho 仅 0.175，低于预设 0.50；P1 对目标也仅 0.350。说明“两个 route 给出相似数值排序”不意味着该分数可以判断另一个 route 的动作风险。E11 因而保护了 8 validation + 8 heldout clean tasks，没有消耗它们。


同一个 89-feature 分数：为何不能直接部署



根据 E4、E11 和 E12 的已保存结果重绘。红色条是未达到 0.50 的有效性门槛。

E12 给了这个故事最有解释力的收尾。它不再把 score 转移到 F1，而是在部署 P1 的同一次 speculative forward 中读取 score、判断该 forward 自己的 P1 action risk；在因果上是合法的。128 个任务不重叠的新状态上，冻结 89-feature score 的 rho 只有 0.211，95% hierarchical-bootstrap CI 为 [-0.334, 0.146]，top-20% AUROC 0.531，接近随机。反而只用五个动作几何量的 baseline 是 0.544；两者差值 CI 为 [-0.792, -0.192]，强烈指向 semantic score 更差。

Figure D Route-variant diagnostic: the frozen E4 score tracks a reuse route that is not the deployed P1 (discovery only)



E12 已保存的 route-variant diagnostic：score 排序相近，但两种 route 的 risk 排序近乎无关。

审计诊断出为什么会这样：冻结 score 对它最初采集的 stale/raw-latent reuse route 自己的风险仍有 rho 0.451；对部署 P1 风险则仅 0.211。两 route 的 score 排序相关为 0.813，但 risk 排序相关为 -0.227。也就是说，estimator 不是“数学上坏了”，它是在预测另一个接口的风险。系统研究里这是一个非常重要的教训：同一模型、同一 feature、甚至相近的 score 分布，都不能替代“估计器与被决策对象来自同一运行时 route”的因果合同。

9. 最终证据表：哪些设计被保留，哪些被停止？

设计/假设	证据	最终阅读
PV0: fresh prefix + persistent latent	3,801 states/40 tasks 全部 Phase-A gates; 200-episode PV0 17 vs P1 11; E12 新任务 128/128 改善	最强正面机制。 值得作为论文系统核心，但表述为 correction/recovery，不是替代 F1。
晚层 visual patch / low-rank correction	视觉修复随深度坍塌; rank-32 只恢复约 28.3% exact-patch 收益	NO-GO。 控制信息已被编译，晚修不够。
固定 R2	8-scenario pilot 与 F1/PV0-always 同为 2/8, P1 占 61.9%	效率候选。 不足以当通用机制。
ESP / selective camera	关联弱; 最低双相机开销 29.5% F1	NO-GO。 刷新成本不可分，proxy 也不稳。
E4 中间层 89 features	历史 rho .651, 但 +5.25 ms; E12 部署 P1 rho .211 且逊于 action-only	主线停止。 旧证据仅描述 stale/raw-latent route。
Raw physical innovation E5	低成本但 heldout rho .453, 有负相关 task	NO-GO。 物理变化不等于控制风险。
S×I 乘法 / prediction age	乘法 .734 < 加法 .747; age 在 H=16 中是常量且 E8 标签错位	NO-GO。 不支持强交互叙事。
semantic scheduler / commitment	E11 F1 transfer .175; E12 P1-native .211	NO-GO。 不应继续消耗 clean validation/ heldout。


10. 对论文设计的可用结论

如果将本轮成果组织成系统论文雏形，最稳的中心命题应是：**在单步 video-world action model 中，预测 latent 的价值不在于无条件地替代物理观测，而在于作为持续上下文被保留；新鲜物理视觉应以低延迟、前置于生成过程的 persistent condition 写入，以修复执行后产生的状态偏差。**

三个可模块化叙事是：(1) **Persistent-condition interface**: PV0 的 fresh-prefix 注入与缓存更新；(2) **H=16-aligned replay/evaluation substrate**: 把模拟器 state 只用于重建观察，并严格对齐 source/target 16 actions；(3) **route-aware validation discipline**: 不要用不同 runtime route 收集的 signal 去决策另一条 route。第 (3) 点来自 E4→E12 的负面结果，反而增强论文的可信度。

不应把论文主张建立在“中间层 feature 自动揭示不确定性”或“一个通用 scheduler 能聪明选择 refresh”上。当前证据支持的是无训练、单步去噪、无 value 的因果条件校正；它同时清楚界定了这种机制的边界：PV0 可恢复 P1 对 F1 的动作一致性，却尚未证明能普遍超过 F1，也没有证明何时可以选择性跳过 correction。

Figure 3 PV0 correction utility on the new discovery tasks



E12 已保存图：在新任务状态上，PV0 correction 的动作风险系统性低于 P1。

11. 可复现性、边界与阅读建议

本报告只综合已保存的结果。核心原始报告分别为：`reports/MECHANISM\_DISCOVERY\_RESULTS.md`、`reports/pv0\_overnight/FINAL\_PV0\_REPORT\_ZH.md`、`reports/pv0\_execution\_feedback/fixed\_reuse\_pilot/FIXED\_REUSE\_PILOT\_REPORT\_ZH.md`、`reports/esp/ESP\_SERVER\_REPORT\_ZH.md`、`reports/semantic\_risk/SEMANTIC\_RISK\_SERVER\_REPORT\_ZH.md`、`reports/sensitivity\_horizon/SENSITIVITY\_HORIZON\_SERVER\_REPORT\_ZH.md`、`reports/semantic\_commitment/SEMANTIC\_COMMITMENT\_SERVER\_REPORT\_ZH.md`、`reports/p1\_semantic\_verify/P1\_SEMANTIC\_VERIFY\_SERVER\_REPORT\_ZH.md`。

本报告不把 discovery 或 pilot 结果包装为正式泛化结论，也不把因 temporal mismatch 而停止的 E8 说成“失败的算法”。8+8 的 E11 clean validation/heldout task split 仍未产生 outcome，应继续保留。未来若有新研究协议，可以针对一个新的、route-local 且低成本的 estimator 做 discovery；但这将是新设计，而不是本轮现有分数的延续。

最终结论。 这轮实验最有价值的不仅是找到 PV0，也包括严格地排除了看似诱人的替代解释：晚层 patch 太迟，视觉差分不稳定，固定年龄没有可识别性，内部特征的历史相关性不等于部署有效性。剩下的坚实事实是：对于 Cosmos WAM，真实物理反馈需要在控制信息被网络“编译”之前进入持续条件；做到这一点，PV0 能可靠地修复预测复用。